Скрытый налог маршрутизации Трансформеров: От вынужденной сериализации к латентной когнитивной диффузии

A Preprint

Анонимный Исследователь*
Независимый разработчик ПО
Full-Stack & Embedded Systems Developer
spore20ka@gmail.com

14 апреля 2026 г.

Abstract

В современной парадигме Больших Языковых Моделей (LLM) принято считать, что параметры слоев Attention и Mixture-of-Experts (MoE) используются исключительно для семантического представления и логического вывода. Однако анализ информационной физики внутри классического остаточного потока (residual stream) выявляет критическое узкое место: механизм одноканальной маршрутизации. Оставшись без выделенной системной шины, градиентный спуск (SGD) перепрофилирует ценные рабочие параметры нейросети под создание тяжеловесных служебных протоколов связи, вводя суровый «скрытый налог на маршрутизацию». В статье описывается, как этот архитектурный изъян приводит к вынужденному переплетению признаков и скрытой сериализации. Более того, мы переосмысливаем феномен *PreNorm Dilution* — часто рассматриваемый просто как математический дефект — как эволюционную адаптацию («Разбухание как стратегия выживания»), при которой слои экспоненциально увеличивают амплитуду своих выходов, чтобы преодолеть интерференцию в слепом конвейере. В архитектурах MoE эта однонаправленность вызывает «защитное дублирование», вынуждая ранних экспертов кэшировать избыточные примитивы из-за отсутствия обратных связей. Хотя последние достижения, такие как Attention Residuals (arXiv:2603.15031), обеспечивают важную нормализацию пайплайна, они остаются однонаправленным компромиссом. Для полного преодоления этих ограничений предлагается архитектура «Латентной когнитивной диффузии» — гибридный фреймворк MoE-Diffusion, заменяющий линейный пайплайн итеративным циклом консенсуса, осуществляющим переход от однонаправленной передачи данных к многомерной латентной рефлексии.

Keywords Трансформеры · Mixture-of-Experts · Маршрутизация · PreNorm Dilution · Диффузионные модели · LLM

1 Введение: Иллюзия чистых знаний

В современной архитектуре LLM принято считать, что миллиарды параметров в слоях Attention и Mixture-of-Experts (MoE) тратятся исключительно на полезную работу: хранение фактов, извлечение паттернов и логические рассуждения. Однако физика передачи информации внутри классического остаточного потока (Residual Stream) вскрывает фундаментальный изъян.

*Данная статья представляет концептуальный фреймворк и архитектурную гипотезу.

Исторически архитектурный пайплайн передачи данных по оси глубины был «пущен на самотек». Оставшись без выделенной системной шины маршрутизации, алгоритм оптимизации (Градиентный спуск — SGD) был вынужден адаптироваться. Он автоматически перепрофилировал драгоценные рабочие параметры нейросети под создание тяжеловесных служебных протоколов связи.

В этой статье мы разберем, как этот «налог на маршрутизацию» ломает концепцию чистых экспертов, почему разбухание векторов — это эволюционная стратегия сети, и как это связано с грядущим переходом к диффузионным когнитивным архитектурам.

Эпистемологический статус (Disclaimer): Все описанное ниже — это архитектурные рассуждения, концептуальные гипотезы и попытка взглянуть на физику движения информации в нейросетях под нестандартным углом. Мы не претендуем на абсолютную истину: факты и предположения требуют строгой эмпирической проверки на вычислительных ресурсах масштаба крупных ИИ-лабораторий. Воспринимайте этот текст как приглашение к дискуссии об архитектурных «узких местах» и векторе дальнейшего развития фундаментальных моделей.

2 Слепой пайплайн и вынужденная криптография

Классическая архитектура Трансформера (Vaswani et al., 2017) предоставляет слоям лишь один общий вектор-контейнер для обмена данными. Если раннему 5-му слою нужно передать критически важный факт 50-му слою-потребителю, этот сигнал должен выжить, пройдя через 44 промежуточных блока.

Из-за того, что сеть оставлена наедине с этой проблемой без явных механизмов маршрутизации, внутри весов стихийно выстраивается скрытая логистическая инфраструктура:

1. **Скрытая сериализация (Упаковка):** Контейнер вынужден запоминать не только сам «вектор знаний», но и методы его кодирования. Ранний слой зашифровывает факты в многомерную суперпозицию, снабжая её скрытым ключом (адресом).

2. **Вынужденное переплетение (Entanglement):** Промежуточные слои тратят свою вычислительную емкость на то, чтобы бережно проносить эти заархивированные пакеты через себя, переплетая чужой транзитный сигнал со своими вычислениями так, чтобы не разрушить его матричными умножениями.

3. **Десериализация (Распаковка):** Глубоким слоям приходится расходовать миллионы параметров на создание «дешифраторов». Они обязаны отфильтровать накопившийся шум, распознать ключ, «разжать» контейнер и лишь потом приступить к полезной логической обработке.

Итог: Модель расходует гигантскую часть своего «интеллекта» на функции системного роутера и ZIP-архиватора, вместо выполнения чистого инференса.

3 Разбухание контейнера как эволюционная адаптация

Академические статьи часто описывают неконтролируемый рост значений вектора по мере прохождения слоев (PreNorm Dilution / Output Magnitude growth) как чисто математический недостаток функции сложения.

Но через призму проблемы маршрутизации становится ясна истинная физическая причина: *Разбухание — это вынужденная адаптация*.

Когда десятки блоков пытаются записать свои запароленные архивы в одну узкую трубу, возникает жесточайшая интерференция. Как раннему слою гарантировать, что его архив не сотрется? Ответ: начать математически «кричать». Слои вынуждены экспоненциально выкручивать амплитуду своих выходов, чтобы их данные доминировали над шумом последующих слоев. Разбухание магнитуды — это стратегия выживания в условиях отсутствия нормальной выделенной шины маршрутизации.

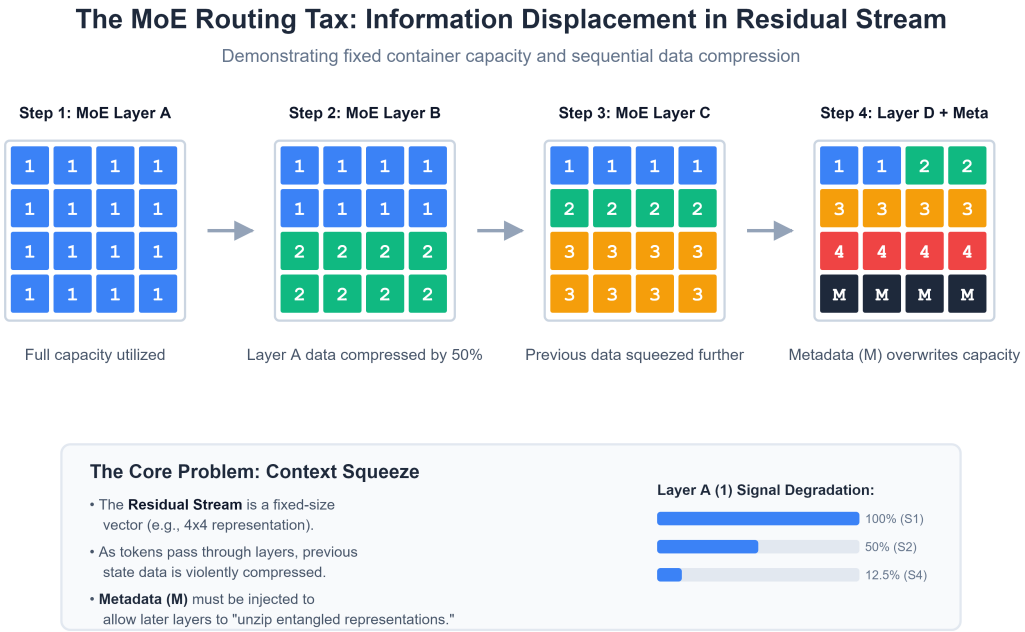

Рис. 1: Скрытая логистическая инфраструктура остаточного потока. Промежуточные слои функционируют как вынужденные маршрутизаторы, переплетая и дешифруя транзитные представления данных.

4 Тупик MoE и «защитное дублирование»

Архитектура Mixture-of-Experts (MoE) (Shazeer et al., 2017) задумывалась как элегантная база узкоспециализированных знаний. Но из-за сломанного пайплайна эксперты оказались в заложниках. Градиентный спуск заставляет их быть не только знатоками своей области, но и криптографами.

Из-за однонаправленной природы пайплайна возникает критическая проблема: невозможность пересмотра и полное отсутствие обратной связи. Ранние слои работают вслепую — у них нет возможности обратиться к конечным слоям и выяснить, какие именно грани данных понадобятся в конце логической цепи.

Как следствие, маршрутизаторы MoE вынуждены заниматься **защитным дублированием**. Они сохраняют и транслируют дальше избыточные примитивы, обрывки контекста и дублирующуюся информацию просто «на всякий случай». Именно эта неспособность архитектурно «пересмотреть» свои выводы порождает избыточность параметров, а также галлюцинации и логические сбои при генерации сложных ответов.

5 Компромисс реальности: Attention Residuals

Индустрия начинает системно осознавать проблему. В недавнем препринте от команды Moonshot AI (Kimi), *Attention Residuals* (Kimi Team, 2026), предложен архитектурный патч, учитывающий жесткие ограничения современных вычислительных ресурсов.

Понимая, что полная переработка стоит непомерно дорого, авторы нормализовали пайплайн, заменив жесткое накопление на механизм селективного внимания (Attention) по оси глубины. Поздние слои получили возможность точечно обращаться к конкретным ранним слоям, минуя транзитное сжатие. Нагрузка на «контейнеры» резко упала, а эффективная размерность шины данных увеличилась, позволив извлекать факты с минимальной компрессией.

Это выдающееся достижение, но оно остается компромиссом. Архитектура *Attention Residuals* блестяще решает проблему извлечения из прошлого, но оставляет пайплайн строго однонаправленным. Первые слои MoE по-прежнему лишены обратной взаимосвязи с последующими. А значит, первопричина «защитного дублирования» — невозможность итеративного пересмотра гипотез — не устранена.

6 Видение будущего: Latent Cognitive Diffusion

Как архитектурно избавиться от «вынужденного дублирования» и научить сеть истинной рефлексии? Концептуальный ответ лежит в гибриде парадигмы MoE и принципов диффузионных моделей, работающих непосредственно в скрытом пространстве (Latent Space).

Понятно, что сегодня реализация этого требует практически недоступных вычислительных ресурсов. Но в идеале процесс генерации должен перейти от линейного пайплайна к **Итеративному Циклу Консенсуса**:

1. **Первичная диффузия (Веер гипотез):** Различные эксперты (MoE) параллельно распаковывают свои независимые срезы знаний, формируя многомерное «облако сырых гипотез».
2. **Обратная диффузия (Кросс-рефлексия):** Сгенерированные состояния не идут слепо дальше по трубе. Они направляются назад и прогоняются через каждого эксперта заново. Возникает петля обратной связи: глубокий эксперт по логике может скорректировать и дополнить ранние данные эксперта по фактам.
3. **Схлопывание (Консенсус):** Этот итеративный денойзинг продолжается, пока эксперты взаимно не вычистят шум и не разрешат противоречия. Только после этого облако гипотез схлопывается в детерминированный вектор, свободный от дублирования примитивов.

Гонять данные туда-обратно через пулы экспертов означает кратное падение скорости инференса и рост требований к железу. Поэтому сейчас индустрия идет путем компромиссов. Но вектор задан: нейросети будущего перестанут быть однонаправленными курьерами-архиваторами и превратятся в *Latent Cognitive Diffusion* системы, где знания не просто транслируются, а итеративно осознаются.

7 Заключение и перспективы

Выявление «Скрытого налога на маршрутизацию» обнажает фундаментальную неэффективность текущих LLM: растрату миллиардов параметров на логистику, а не на когнитивные вычисления. В то время как такие инновации, как Attention Residuals, смягчают симптомы (PreNorm Dilution и вынужденную сериализацию), они не решают проблему однонаправленной слепоты, вызывающую Защитное дублирование. Теоретический сдвиг к Латентной когнитивной диффузии представляет собой следующую тектоническую эволюцию. Заменив жесткие направленные графы итеративными циклами консенсуса, модели смогут вернуть «налог на маршрутизацию» и превратиться из огромных ZIP-архиваторов паттернов в системы глубокой многомерной рефлексии.

References

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, pages 5998–6008, 2017.

Noam Shazeer, Azalia Mirhoseini, Krzysztof Maziarz, Andy Davis, Quoc Le, Geoffrey Hinton, and Jeff Dean. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *arXiv preprint arXiv:1701.06538*, 2017.

Kimi Team (Moonshot AI). Attention Residuals. *arXiv preprint arXiv:2603.15031*, 2026.